

# Comparativa de Estrategias de IA para Clasificación de Tumores Cerebrales en MRI

**Juan Camilo Salazar**

**Brayan Steven Ortega**

**Andrés Camilo Romero**



# Introducción

## **Diagnóstico Temprano de Tumores Cerebrales**

El diagnóstico preciso y temprano es crucial para el tratamiento y pronóstico de los tumores cerebrales. La detección a tiempo puede marcar una diferencia significativa en la vida del paciente.

## **Objetivo del Trabajo**

Implementar y comparar tres enfoques de IA de la literatura reciente, adaptándolos para hacerlos viables computacionalmente en nuestro entorno.

# Metodología: Tres Enfoques Implementados

1

CNN Personalizada  
Reducida

**Original:** CNN Profunda (8 capas conv.) + Autoencoder

**Nuestra Adaptación:** CNN Personalizada (4 capas conv.) con menos filtros.

2

SVM con HOG + LBP + PCA

**Original:** SVM + HOG + LBP + PCA

**Nuestra Adaptación:** Uso de subconjunto de imágenes por tiempo y recursos.

3

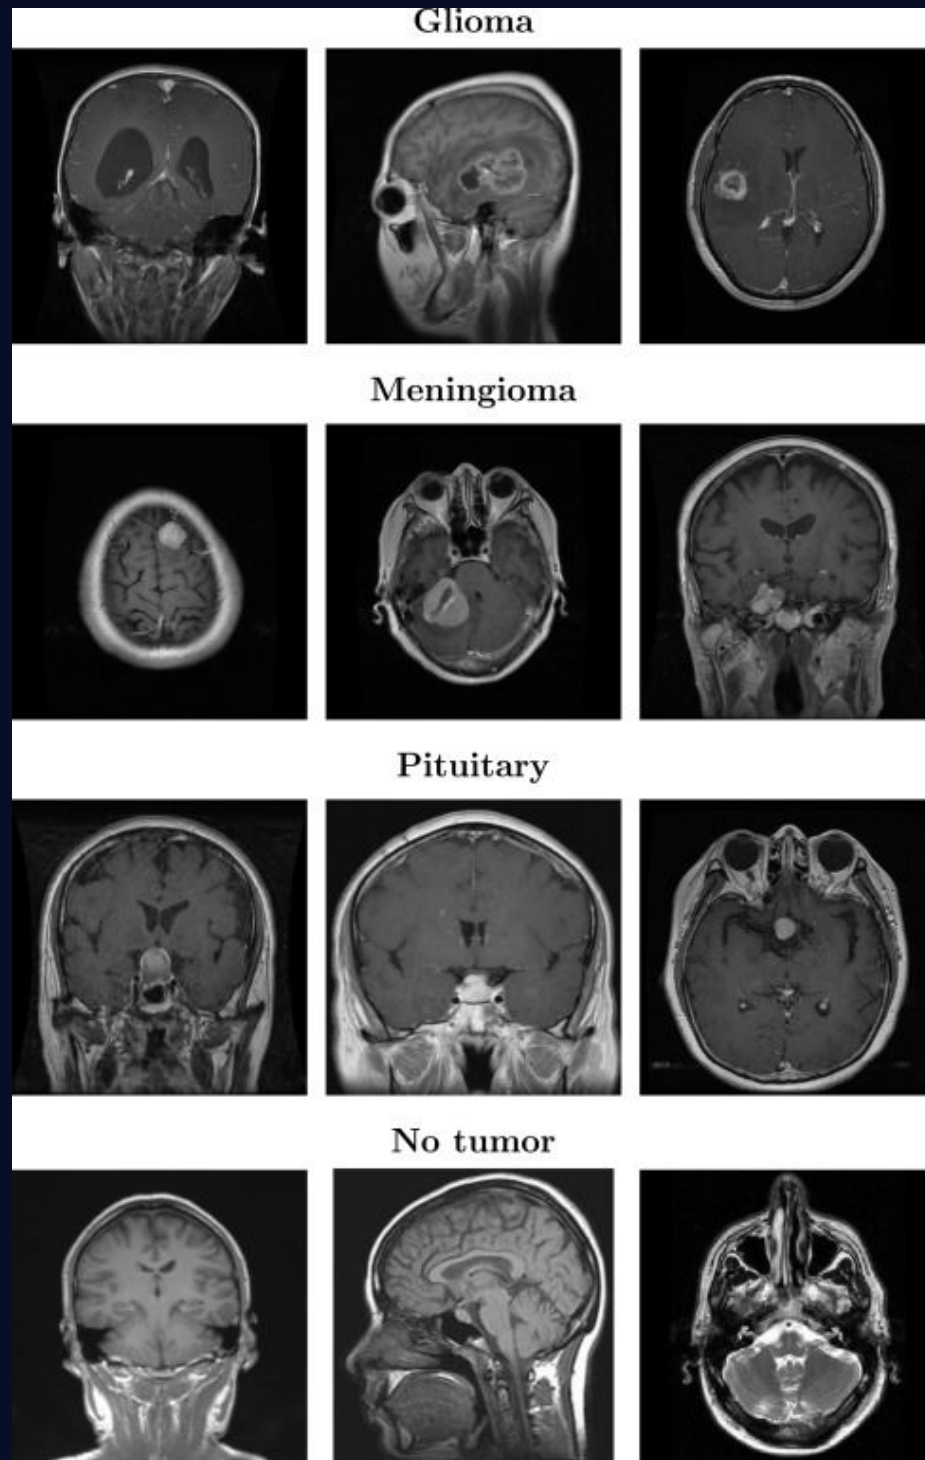
VGG16 con Transfer  
Learning

**Original:** Ensamble CNNs (VGG16, DenseNet, Inception-ResNet) + XAI

**Nuestra Adaptación:** Solo VGG16 por limitaciones computacionales.

# Dataset y Preprocesamiento:

Fuente: "Brain Tumor MRI Dataset" de Kaggle. Más de 7.000 imágenes



## Preprocesamiento Aplicado

### Redimensionamiento

Imágenes a 224x224 píxeles para uniformidad.

### Normalización

Valores de píxeles escalados para mejor desempeño del modelo.

### Data Augmentation

Rotaciones y flips para modelos de Deep Learning (VGG16 y CNN Personalizada) para aumentar el tamaño del dataset y mejorar la generalización.

### Escala de Grises

Conversión de imágenes a escala de grises para todos los modelos, reduciendo la complejidad.

# Implementación Técnica y Dificultades



## CNN Personalizada

**Arquitectura:** [Conv2D(8) → Conv2D(16) → MaxPooling] x 2 → Flatten → Dense.

**Dificultad:** Modelo original, muy pesado en recursos y tiempo.

**Solución:** Reducción de capas y canales, manteniendo la esencia.



## SVM con HOG/LBP/PCA

**Pipeline:** Extracción HOG + LBP → Normalización → PCA → SVM (kernel RBF).

**Dificultad:** Extracción de características lenta para dataset completo.

**Solución:** Submuestreo balanceado (300 imágenes/clase).




## VGG16 con Transfer Learning

**Estrategia:** Fine-tuning parcial (capas superiores entrenables, base congelada).

**Dificultad:** Ensemble completo prohibitivo computacionalmente.

**Solución:** Implementación individual de VGG16 con hiperparámetros ajustados.

# Resultados y Comparativa de Performance



# Conclusiones y Recomendaciones

## 1 CNN personalizada

Ofrece el mejor balance entre precisión y viabilidad computacional.

## 2 Enfoque clásico (SVM + características)

Más eficiente en recursos y suficientemente preciso para ciertos entornos. Además de ser explicable

## 3 Transfer Learning con VGG16

Requirió más ajuste pero tiene un gran potencial con más recursos.

## Limitaciones Enfrentadas

- **Recursos Limitados**
- **Tiempos de Entrenamiento**
- **Costo Computacional**

# Mejoras Potenciales



## Fine-tuning Agresivo

Probar ajuste más profundo en VGG16.



## Ensemble Completo

Implementar el ensemble original con recursos adecuados.



## Explainable AI (XAI)

Explorar Grad-CAM para mayor interpretabilidad.



## Datasets

Probar con datasets más grandes y balanceados.



# Referencias

Sánchez-Moreno et al. (2025). *Computers in Biology and Medicine*.

Saeedi et al. (2023). *BMC Medical Informatics and Decision Making*.

Bashikodi et al. (2024). *Scientific Reports*.

Dataset: "Brain Tumor MRI Dataset" de Kaggle.

Todos los modelos se implementaron en Python usando TensorFlow/Keras para CNN y scikit-learn/OpenCV para SVM.

